UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

MURILO KENJI CARDOSO

APLICAÇÃO DE UM MODELO DE APRENDIZADO DE MÁQUINA ENVIESADO: DETECÇÃO DE FRAUDES EM TRANSAÇÕES DE CARTÃO DE CRÉDITO NO COMÉRCIO ELETRÔNICO

CURITIBA

2022

MURILO KENJI CARDOSO

APLICAÇÃO DE UM MODELO DE APRENDIZADO DE MÁQUINA ENVIESADO: DETECÇÃO DE FRAUDES EM TRANSAÇÕES DE CARTÃO DE CRÉDITO NO COMÉRCIO ELETRÔNICO

Trabalho de conclusão de curso de Especialização apresentado como requisito para obtenção do título de Especialista em Ciência de Dados e suas Aplicações da Universidade Tecnológica Federal do Paraná (UTFPR).
Orientador: Matheus Garibalde Soares De Lima.

CURITIBA

2022

4.0 Internacional

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

TERMO DE APROVAÇÃO

APLICAÇÃO DE UM MODELO DE APRENDIZADO DE MÁQUINA ENVIESADO: DETECÇÃO DE FRAUDES EM TRANSAÇÕES DE CARTÃO DE CRÉDITO NO COMÉRCIO ELETRÔNICO

por

Murilo Kenji Cardoso

Este Trabalho de Conclusão de Curso foi apresentado às 19h do dia 11 de novembro de 2022 por videoconferência como requisito parcial à obtenção do grau de Especialista em Ciência de Dados e suas Aplicações na Universidade Tecnológica Federal do Paraná - UTFPR - Campus Curitiba. O aluno foi arguida pela Banca de Avaliação abaixo assinados. Após deliberação, a Banca de Avaliação considerou o trabalho aprovado.

_____

Prof. Msc. Matheus Garibalde Soares de Lima (Presidente/Orientador – Grupo BOTICÁRIO)

_____

Profa. Dra. Rita Cristina Galarraga Berardi (Avaliador 1 – DAINF-CT/ UTFPR-CT)

_____

Prof. Dr. Luiz Celso Gomes Jr (Avaliador 2 – DAINF-CT/ UTFPR-CT)

O Termo de Aprovação assinado encontra-se no sistema SEI- Processo nº 23064.056463/2022-09

RESUMO

O estudo de caso ocorre em um contexto de grande volume de tentativas de fraudes no comércio eletrônico, especificamente cartões de crédito. O trabalho busca criar um modelo de aprendizado de máquina que vise o acerto da classe positiva, atuando como um intermediário para evitar a utilização de modelos ofertados no mercado de prevenção a fraudes. A metodologia aplicada consistiu em tratamento dos dados, seleção das melhores variáveis, correção de desbalanceamento da classe minoritária, aplicação dos algoritmos *Random Forest*, Regressão Logística e *Gradient Boosting*, tunagem de hiperparâmetros dos algoritmos, seleção do limiar de classificação e criação de faixas com sugestões de maior ou menor exposição ao risco. Como resultado, foi possível observar um baixo volume de erro da classe positiva e a possibilidade de evitar a utilização de até 80% do modelo de mercado estudado.

Palavras-chave: prevenção a fraudes; modelo enviesado; *Random Forest*; Regressão Logística; *Gradient Boosting.*

ABSTRACT

The case study occurs in a context of high volume of fraud attempts in e-commerce, specifically with credit cards. The work seeks to create a machine learning model that aims to hit the positive class, acting as an intermediary to avoid the use of models offered in the fraud prevention market. The applied methodology consisted of data processing, selection of the best variables, correction of minority class imbalance, application of Random Forest, Logistic Regression and Gradient Boosting algorithms, tuning algorithms' hyperparameters, selection of threshold and creation of ranges with suggestions of greater or lesser exposure to risk. As a result, it was possible to observe a low volume of error in the positive class and the possibility of avoiding the use of up to 80% of the market model studied.

Keywords: fraud prevention; biased model; Random Forest; Logistic Regression; Gradient Boosting.

LISTA DE ILUSTRAÇÕES

Figura 1 - Fluxo antifraude transacional atual……..……..9
Figura 2 - Fluxo antifraude transacional proposto……..……...9
Figura 3 - Matriz de confusão……...……..13
Figura 4 - Aplicação *Z-score*……..…….……15
Quadro 1 - Compilação de referências bibliográficas……12
Quadro 2 - Variáveis da base de dados……16

TABELAS

Tabela 1 - Resultados *Gradient Boosting*……..…….…….25
Tabela 2 - Resultados Regressão Logística…….…….26
Tabela 3 - Resultados *Random Forest*……..26
Tabela 4 - Comparação dos modelos faixa menor que 20%……..…..……27
Tabela 5 - Comparação dos modelos faixa maior ou igual a 20% e menor que 40%……..……..……..……..27
Tabela 6 - Comparação dos modelos faixa maior ou igual a 40% e menor que 60%……..……..……..……..28
Tabela 7 - Comparação dos modelos faixa maior ou igual a 60% e menor que 80%……..……..……..……..28
Tabela 8 - Comparação dos modelos faixa maior ou igual a 80% e menor ou igual a 100%……..……...…..……..…….29

SUMÁRIO

1 INTRODUÇÃO…….. 7
1.1 Objetivos…… 8
2 REVISÃO DA LITERATURA…… 11
2.1 Estudo de referências……11
2.2 *Gradient Boosting*…….. 12
2.3 Regressão Logística…… 12
2.4 *Random Forest*……13
2.5 Métricas de avaliação do modelo……13
2.6 Desbalanceamento de variáveis……...14
2.7 Seleção de variáveis……...14
2.8 Normalização de variáveis…… 15
3 MATERIAIS E MÉTODOS…….. 16
3.1 Software…… 16
3.2 Base de dados……..16
3.2.1 Composição da variável alvo…… 19
3.3 Seleção de variáveis…… 19
3.4 Separação base treino e teste…… 21
3.5 Dados desbalanceados…… 21
3.6 Aplicação dos modelos e ajuste de hiperparâmetros…… 21
3.6.1 Hiperparâmetros *Gradient Boosting*…… 22
3.6.2 Hiperparâmetros Regressão Logística……23
3.6.3 Hiperparâmetros *Random Forest*…… 23
3.7 Limiar de classificação…….. 24
3.8 Resultados…… 24
5 CONSIDERAÇÕES FINAIS…… 27
REFERÊNCIAS…… 30

1 INTRODUÇÃO

O art. 171 do Código Penal conceitua fraude ou estelionato como a obtenção, para si ou para outrem, de vantagem ilícita, em prejuízo alheio, induzindo ou mantendo alguém em erro, mediante artifício, ardil, ou qualquer outro meio fraudulento.

Segundo o Sebrae (2013), o comércio eletrônico é uma atividade mercantil que realiza sua transação via conexão eletrônica entre a empresa e o cliente para a venda de produtos ou serviços. Essa atividade se tornou uma realidade no perfil de compras dos brasileiros, onde no cenário de pré-pandemia de 2019 já apresentava um crescimento e ganho de espaço frente ao varejo físico e com o início da pandemia esse processo foi ainda mais acelerado. Segundo o índice de faturamento online (MCC-ENET, 2022), o ano de 2020 apresentou um crescimento de 68,93% em faturamento frente ao seu ano anterior, seguido de 27,97% em 2021 e o acumulado até abril de 2022 já apresenta um crescimento de 13,48%.

Quando olhamos para o comércio eletrônico, de forma proporcional ao seu crescimento, a exposição a fraudes nesse ambiente virtual de compra e venda também cresce. Segundo o relatório Mapa de Fraude (CLEARSALE, 2021), publicado pela consultoria especializada em fraudes Clearsale, 2020 teve um aumento de 53,61% referente ao ano anterior em quantidade de tentativas de fraude, já em 2021 esse número aumentou para 74%.

Najem e Kadeem (2021) apresentam o fluxo que ocorre nesse meio de pagamento:

1. Verificação de validade do número de cartão de crédito;
2. Verificação junto ao banco emissor do cartão a presença de crédito para cobrir o valor total da compra;
3. Solicitação da liquidação da transação.

Segundo os autores, caso o cliente alegue que não recebeu o produto ou não reconhecer uma compra em sua fatura, são adicionados mais dois passos nesse fluxo:

4. O cliente irá entrar com um processo de *chargeback* junto ao banco;

5. O lojista irá analisar o caso tendo a possibilidade ou não de reverter o *chargeback*.

O processo de *chargeback* consiste no estorno de uma venda realizada via cartão, criado pelas operadoras de cartões para proteger seus consumidores de problemas com pagamentos, principalmente os realizados em meios digitais onde não há autenticação por senha (CLEARSALE, 2021).

A fraude no fluxo apresentado pode ocorrer e ser identificada no quarto passo, pelo processo de chargeback, podendo ocorrer de duas formas:

- Fraude confirmada: o requerente do chargeback teve suas informações confidenciais do cartão e de dados pessoais roubados e ocorreu uma transação onde o infrator se passa pela vítima;
- Auto-fraude: o requerente do chargeback foi quem realmente realizou a compra e entrou com o processo para tentar restituir o valor e ficar com o produto.

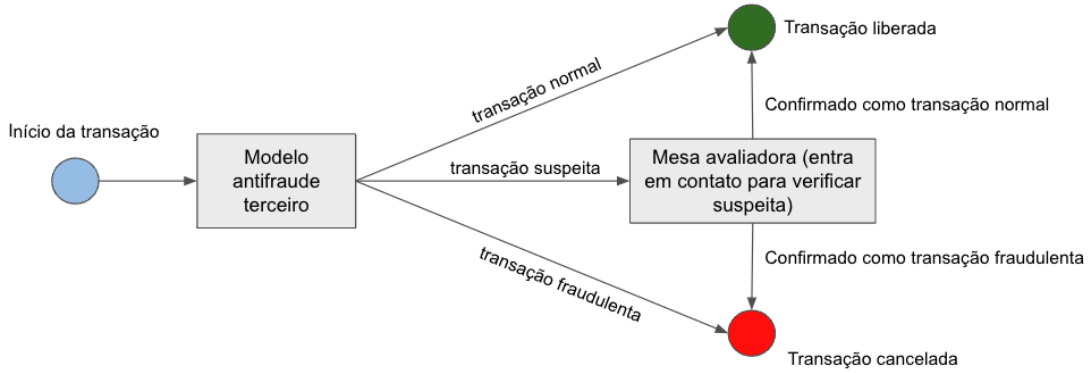
Nesse cenário, o desenvolvimento de mecanismos que permitam a identificação destes casos fraudulentos é essencial para evitar grandes prejuízos financeiros e de imagem. Atualmente existem algumas empresas no mercado que possuem sistemas anti-fraude de transações por cartão de crédito como ClearSale, Konduto, Serasa Experian, entre outras. Os dados e o conhecimento de mercado que essas companhias possuem possibilitam elas a atingir alto índice de assertividade na detecção de fraudes utilizando modelos estatísticos e de aprendizado de máquina, por outro lado, a contratação desses sistemas pode gerar uma alto custo para as empresas.

1.1 Objetivos

O cenário do presente trabalho é identificar possíveis fraudes em compras realizadas através do cartão de crédito sobre uma base de dados de transações ocorridas dentro de um comércio eletrônico de uma empresa brasileira que atua na área de cosméticos.

Atualmente esse comércio eletrônico já possui um modelo disponibilizado por uma empresa especializada em fraudes que é acionado para toda transação de compra ocorrida conforme a Figura 1 abaixo:

Figura 1 - Fluxo antifraude transacional atual



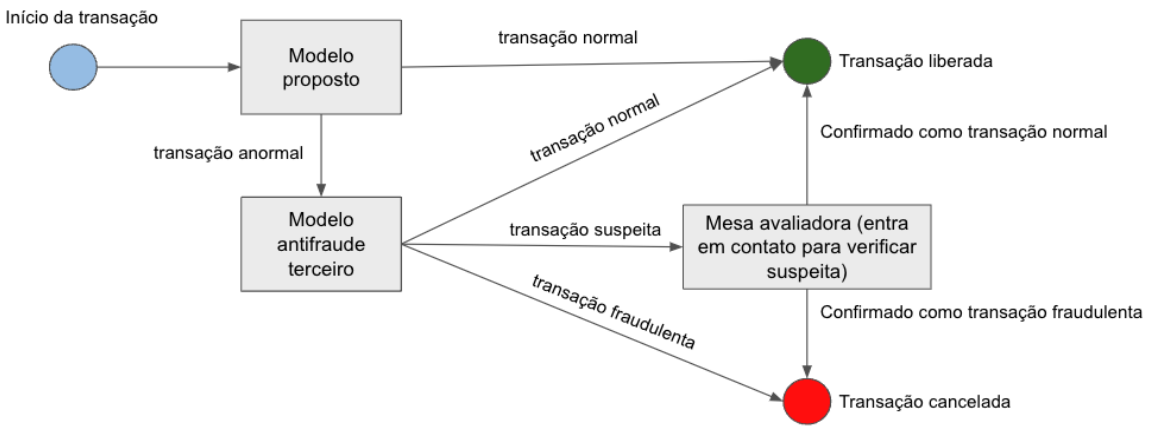
Fonte: o autor (2022)

Podemos averiguar que o modelo tem como resultado para cada transação três categorias:

- Transação normal: liberada automaticamente;
- Transação fraudulenta: cancelada automaticamente;
- Transação suspeita: enviada para análise de uma mesa avaliadora que entra em contato com o cadastro para averiguar a transação, podendo ser liberada ou cancelada conforme decisão manual.

O modelo desenvolvido pretende alterar esse fluxo entre o início da transação e o modelo terceirizado conforme a Figura abaixo:

Figura 2 - Fluxo antifraude transacional proposto



Fonte: o autor (2022)

Podemos observar que o modelo proposto categoriza a transação em normal (liberando ela para consolidação da compra) e anormal (enviando a transação para o modelo terceirizado tomar a decisão final de casos considerados anormais).

Assim, o objetivo do trabalho é criar um modelo de aprendizado de máquina enviesado para o acerto da classe normal, deixando a predição da classe anormal para o modelo terceirizado, e que atue como um intermediário entre o início da transação e o modelo mais robusto. Dessa forma, evitando enviar 100% dos casos para um modelo terceirizado e diminuindo a quantidade de transações processadas pela empresa especializada em antifraude. Como cada transação processada custa cerca de R$ 1,90, evitar seu uso pode gerar economia financeira.

2 REVISÃO DA LITERATURA

2.1 Estudo de referências

Visando levantar cenários semelhantes ao presente trabalho (aplicações de algoritmos em bases de cartão de crédito para prevenção a fraude) e analisar os algoritmos mais utilizados nessa área, foi realizado um estudo de referências.

Com o objetivo de comparar diferentes técnicas de aprendizado de máquina, Rout (2021) aplicou na base *European Cardholder September/2013* que contém informações de dois dias de transações de cartão de crédito da Europa, os algoritmos *Random Forest, Gradient Boosting* e Regressão Logística. O autor percebeu um desbalanceamento na classe minoritária e aplicou a técnica SMOTE (*Synthetic Minority Oversampling Technique*) para sintetizar amostras. Os algoritmos apresentaram resultados satisfatórios analisando a acurácia, sendo o *Random Forest* o melhor colocado (99.96%), seguido pelo Gradient Boosting (99.5%) e por último, a Regressão Logística (99.3%).

Já os autores Nadim, et al. (2019), apresentaram seis algoritmos (*Random Forest, Support Vector Machine, K-Nearest Neighbour,* Regressão Logística, Árvore de decisão, *Gradient Boosting* e *Linear Discriminant Analysis*) aplicados na também base *European Cardholder September/2013*. Os melhores colocados analisando a acurácia foram os algoritmos *Gradient Boosting* (98.4%), Regressão Logística (97.7%) e *Support Vector Machine* (97.5%).

Por último, Trivedi, et al. (2020) aplicaram também na base *European Cardholder September/2013* os algoritmos *K-nearest Neighbors, Random Forest*, Árvore de Decisão, Rede Neural, *Support Vector Machine, Naive Bayes,* Regressão Logística e *Gradient Boosting*. Todos os modelos apresentaram resultados satisfatórios com a acurácia acima de 90%, sendo os melhores desempenhos do *K-nearest Neighbors* (94.99%), seguido do *Gradient Boosting* (94%) e por último o *Support Vector Machine* (93.963%).

Os modelos utilizados nas três referências citadas acima foram compilados no Quadro 1 - Compilação de referências bibliográficas:

Quadro 1 - Compilação de referências bibliográficas

Algorítimo	**Referências**	**Quantidade de utilizações**
Regressão Logística	ROUT, 2021; NADIM, et al. 2019; TRIVEDI, et al. 2020	3
Gradient Boosting	ROUT, 2021; NADIM, et al. 2020; TRIVEDI, et al. 2020	3
Random Forest	ROUT, 2021; NADIM, et al. 2021; TRIVEDI, et al. 2020	3
Naive Bayes	NADIM, et al. 2022; TRIVEDI, et al. 2020	2
Support Vector Machine	NADIM, et al. 2019; TRIVEDI, et al. 2020	2
K-nearest neighbors	NADIM, et al. 2020; TRIVEDI, et al. 2020	2
Árvore de decisão	TRIVEDI, et al. 2020; NADIM, et al. 2022	2
Linear Discriminant Analysis	NADIM, et al. 2021	1
Rede Neural	TRIVEDI, et al. 2020	1

Fonte: o autor (2022)

Podemos perceber pelo Quadro 1 que os modelos Regressão Logística, Gradient Boosting e Random Forest foram os mais utilizados e todos obtiveram resultados satisfatórios frente a métrica de acurácia. Por essa razão, os três algoritmos foram os escolhidos para aplicação no presente trabalho.

2.2 *Gradient Boosting*

O algoritmo Gradiente Boosting consiste em uma das variantes da metodologia Ensemble, que consiste em criar vários modelos fracos e os combiná-los para obter um melhor desempenho como um todo. O algoritmo envolve três elementos: uma função de perda para ser otimizada, um algoritmo fraco para realizar predições e um modelo adicionado ao algoritmo fraco para minimizar a função de perda (NATEKIN; KNOLL, 2013).

2.3 Regressão Logística

A regressão logística permite estimar a probabilidade (contido entre zero e um) associada à ocorrência de determinado evento em face de um conjunto de variáveis explanatórias. A probabilidade de ocorrência do evento binário é calculada utilizando uma função logit. Como benefício, esse algoritmo é matematicamente menos complexo, o que exige um poder computacional menor e possibilita o processamento de grandes quantidades de dados (LAVALLEY, 2008).

2.4 *Random Forest*

O algoritmo *Random Forest, assim* como o *Gradient Boosting,* é uma variante do metodologia *Ensemble* e consiste em um grande número de árvores de decisão individuais que operam como um conjunto. Cada árvore individual na floresta aleatória resulta em uma previsão de classe e a classe com mais votos se torna a previsão do nosso modelo (BREIMAN, 2001).

2.5 Métricas de avaliação do modelo

Uma forma de comparar técnicas e avaliar o desempenho de modelos é utilizar a matriz de confusão e indicadores como acurácia, precisão, recall e F1-score que são extraídas a partir da matriz. Segundo Izibick e Mendonça (2020), matriz de confusão é uma tabela que indica os erros e acertos, comparando o resultado esperado com o realizado conforme abaixo:

Figura 3 - Matriz de confusão

Valor Predito	**Valor verdadeiro**	
	$Y = 0$	$Y = 1$
$Y = 0$	VN (verdadeiro negativo)	FN (falso negativo)
$Y = 1$	FP (falso positivo)	VP (verdadeiro positivo)

Fonte: Izibick e Mendonça (2020)

Os valores mostrados acima representam:

- Verdadeiros Positivos (VP): classificação correta da classe positivo;
- Falsos Negativos (FN): classificação incorreta onde a previsão foi classe negativo quando o correto seria positivo;
- Falsos Positivos (FP): classificação incorreta onde a previsão foi classe positivo quando o correto seria negativo;
- Verdadeiros Negativos (VN): classificação correta da classe negativa.

Izibick e Mendonça (2020), também trazem alguns indicadores que podem ser extraídos a partir da matriz de confusão:

- Acurácia: entre todas as classificações, quantas foram classificadas corretamente. A fórmula utilizada é (VP + VN) / (VP + VN + FP + FN);
- Precisão: entre as classificações de classe positiva, quantas foram classificadas corretamente. A fórmula utilizada é VP / (VP + FP);
- Revocação: entre todas as classificações de classe positiva, quantas estão corretas. A fórmula utilizada é VP / (VP + FN);
- F1-Score: média harmônica entre precisão e recall. A fórmula utilizada é 2 * (precisão * revocação) / (precisão + revocação)

2.6 Desbalanceamento de variáveis

O desbalanceamento de variáveis envolve o desenvolvimento de modelos de classificação em um conjunto de dados que apresenta um desequilíbrio de quantidades de positivos e negativos da classe alvo. O desafio de trabalhar nesse cenário é que a maioria das técnicas de aprendizado de máquina terá um desempenho ruim na classe minoritária.

Uma abordagem para lidar com conjuntos de dados desequilibrados é sobreamostrar a classe minoritária, essa técnica consiste em aumentar a quantidade de registros minoritários sintetizando novos a partir dos já existentes. Um dos algoritmos que utilizam esse conceito de sobreamostragem é o SMOTE, ele funciona selecionando uma instância de classe minoritária aleatoriamente e encontrando seus n-vizinhos mais próximos. A instância sintética é então criada escolhendo um dos n-vizinhos mais próximos aleatoriamente e conectando um ao outro para formar um segmento de linha no espaço de características. As instâncias sintéticas são geradas como uma combinação convexa das duas instâncias escolhidas (YUNQIAN; HAIBO, 2013).

2.7 Seleção de variáveis

A seleção de variáveis busca por um modelo que vise o mínimo de variáveis preditoras, independentes e que sejam capazes de predizer bem a variável resposta. Na seleção, podemos reduzir o custo computacional no processo de treino e dar velocidade no processo de desenvolvimento. Além disso, o desempenho de alguns modelos pode degradar ao incluir variáveis de entrada que não são relevantes para a variável de destino.

Métodos de seleção de variáveis baseados em estatística podem ser aplicados para selecionar as melhores variáveis ao avaliarem o relacionamento entre cada variável de entrada e a variável alvo. Esses métodos podem ser rápidos e eficazes, embora a escolha de qual usar depende do tipo de dados das variáveis de entrada e de saída (KUHN et al., 2013).

Um dos métodos que podemos utilizar para seleção de variável é a Análise de Variância (ANOVA). Ele é um método estatístico, utilizado para verificar as médias de dois ou mais grupos que são significativamente diferentes entre si. Esse método utiliza a verificação do teste-f para verificar se existe diferença significativa entre os grupos. Se não houver diferença significativa entre os grupos e todas as variâncias são iguais, o resultado da razão F da ANOVA será próximo de 1 (RUTHERFORD, 2000).

2.8 Normalização de variáveis

Segundo Jun-Mo (2019), a normalização tem como objetivo normalizar os valores de um conjunto de dados de modo que a média de todos os valores seja 0 e o desvio padrão seja 1. Isso beneficia o resultado do modelo ao transformar todas as variáveis na mesma ordem de grandeza, além de melhorar a performance computacional.

Entre diversas técnicas, podemos utilizar o *Z-score* como uma ferramenta para tal ação, sendo utilizado em sua fórmula o valor a ser normalizado, média e desvio padrão, definida conforme a Figura 4 - Aplicação *Z-score:*

Figura 4 - Aplicação *Z-score*

$$z = \frac{x - \mu}{\sigma}$$

Fonte: Jun-Mo (2019)

3 MATERIAIS E MÉTODOS

A metodologia para implementação do modelo foi aplicada segundo os seguintes passos: tratamento dos dados, seleção das variáveis, correção de desbalanceamento da base, ajuste de hiperparâmetros, aplicação do modelo, seleção de limiar de classificação e análise dos resultados.

3.1 Software e Hardware

A implementação foi realizada utilizando o JupyterLab em uma máquina com 8 CPUs e 30 GB de RAM com a linguagem Python 3. Os pacotes explorados foram:

- Numpy e Pandas: análise exploratória e tratamento de dados;
- Imblearn: balanceamento de variáveis (SMOTE);
- Sklearn: modelagem (Regressão Logística e *Random Forest*), divisão de base treino e teste, ajuste de hiperparâmetros, normalização das variáveis e conversão das variáveis categóricas em numéricas;
- Xgboost: modelagem (*Gradient boosting*).

3.2 Base de dados

A base utilizada contém informações transacionais de pedidos realizados no comércio eletrônico durante todo o ano de 2021. Contém um total de 1.874.630 registros (cada registro representa uma venda utilizando o cartão de crédito como pagamento) e 28 colunas sendo estas compostas por dados de cadastros, vendas, pagamentos e frete. As 28 colunas após seu tratamento se tornaram 86 colunas. Dentre os tratamento temos o método *one hot encoding* que se baseia em transformar uma coluna categórica em colunas numéricas, contendo 1 para o valor afirmativo e 0 para valor negativo do valor contido, conforme exemplificados pela tabela abaixo:

Quadro 2 - Variáveis da base de dados (continua)

Nome da variável	Valores categóricos possíveis	Conceito	Tratamento
uf	Todas as siglas dos estados brasileiros	Estado do cadastro do cliente	Aplicação *one hot encoding*

Quadro 2 - Variáveis da base de dados (continuação)

Nome da variável	Valores categóricos possíveis	Conceito	Tratamento
uf_diff_ddd	0 ou 1	O estado é diferente do DDD de telefone do cadastro?	N/A
aplicativo	Android, IOS ou Webstore	Aplicativo utilizado pelo comprador	Aplicação *one hot encoding*
tipo_entrega	Super expressa, expressa, normal ou buscar na loja	Tipo de entrega	Aplicação *one hot encoding*
bandeira_cartao	VISA, MASTER, ELO ou OUTROS	Bandeira do cartão	1) Aplicação *one hot encoding* 2) Caso o valor seja diferente de VISA, MASTER ou ELO recebe valor OUTROS
vlr_total	N/A	Valor total do pedido	Aplicação *Z-score*
vlr_frete	N/A	Valor do frete	Aplicação *Z-score*
vlr_desconto	N/A	Valor do desconto do pedido	Aplicação *Z-score*
qtd_compras_anteriores	N/A	Quantidade de compras anteriores que o usuário já realizou	N/A
qtd_parcelas_cartao_credito	N/A	Quantidade de parcelas do pagamento do pedido	N/A
genero	F, M ou X	Genero do cadastro	Caso o gênero fosse nulo realizado troca pela letra X
is_fidelidade	0 ou 1	Participa do programa de fidelidade	N/A
qtd_compras_consolidadas	N/A	Quantidade de compras anteriores que o usuário já consolidou	N/A
qtd_compras_canceladas	N/A	Quantidade de compras anteriores que o usuário já cancelou	N/A
qtd_compras_devolvidas	N/A	Quantidade de compras anteriores que o usuário já devolveu	N/A

Quadro 2 - Variáveis da base de dados (continuação)

Nome da variável	Valores categóricos possíveis	Conceito	Tratamento
qtd_compras_realizadas_cartao	N/A	Quantidade de compras anteriores que o usuário já pagou via cartão de crédito	N/A
qtd_compras_realizadas_a_vista	N/A	Quantidade de compras anteriores que o usuário já pagou à vista (pix ou boleto)	N/A
diff_avg_media_historica	N/A	(Média histórica dos valores dos pedidos do cadastro) - (Valor do pedido)	Aplicação *Z-score*
qtd_itens	N/A	Quantidade de itens	N/A
max_preco_item	N/A	Maior preço dos itens do pedido	Aplicação *Z-score*
avg_preco_item	N/A	Média dos preços dos itens do pedido	Aplicação *Z-score*
qtd_cpf_repetido	N/A	Quantidade do cpf utilizados em outros cadastros	N/A
qtd_tel_repetido	N/A	Quantidade do telefone utilizados em outros cadastros	N/A
dia_semana_pedido	Todos os dias da semana (Segunda-feira até Domingo)	Dia da semana que realizou a compra	Aplicação *one hot encoding*
periodo_pedido	Manhã, Tarde, Noite ou Madrugada	Período que realizou a compra	Aplicação *one hot encoding*
diff_data_criacao_cadastro_pedido	N/A	Quantidade de dias da subtração data de cadastro para data do pedido pedido	Aplicação *Z-score*
idade	N/A	Idade do cliente no cadastro	N/A

Fonte: o autor (2022)

3.2.1 Composição da variável alvo

Para a variável alvo, foram definidos valores 1 ou 0 verificando se o cadastro é considerado normal (1) ou não normal (0). Baseado no fluxo apresentado pela Figura 2 - Fluxo antifraude transacional proposto, os conceitos são:

- Cadastros normais (classe positiva)
    - Modelo terceiro avaliou como transação normal, foi consolidada e não foi gerado chargeback posterior
    - Modelo terceirou avaliou como suspeito, mesa avaliadora considerou como transação normal e não foi gerado chargeback posterior
- Cadastros não normais (classe negativa)
    - Modelo terceiro avaliou como cadastro fraudulento e cancelou a transação
    - Modelo terceiro avaliou como cadastro suspeito e a mesa avaliadora confirmou como transação fraudulenta cancelando a transação
    - Modelo ou a mesa avaliadora aprovaram a transação porém foi gerado um chargeback posterior

3.3 Seleção de variáveis

Com objetivo de selecionar as variáveis mais significativas foram aplicadas duas técnicas sobre as 89 colunas. Inicialmente foi aplicado um teste de correlação entre todas as variáveis e foram removidas aquelas que apresentaram uma correção acima de 0.7. O critério de desempate entre as duas foi a que apresentou a maior correlação com a variável alvo. Em uma segunda etapa, foi aplicado o teste ANOVA, removendo todas as variáveis que apresentavam o valor do teste-f menor que 50.

Após a aplicação dessas etapas, reduziu-se de um total de 86 para 30 variáveis a serem utilizadas nos modelos:

- uf_diff_ddd
- vlr_total
- vlr_frete
- vlr_desconto
- qtd_compras_anteriores
- qtd_parcelas_cartao_credito

- is_fidelidade
- qtd_compras_consolidadas
- qtd_compras_canceladas
- qtd_compras_realizadas_a_vista
- diff_avg_media_historica
- max_preco_item
- avg_preco_item
- idade
- diff_data_criacao_cadastro_pedido
- uf_is_BA
- uf_is_ES
- uf_is_PR
- uf_is_RJ
- uf_is_RS
- uf_is_SC
- tipo_entrega_is_super_expressa
- tipo_entrega_is_buscar_na_loja
- bandeira_cartao_is_ELO
- bandeira_cartao_is_MASTER
- bandeira_cartao_is_VISA
- genero_is_F
- genero_is_M
- periodo_pedido_is_madrugada
- periodo_pedido_is_manha

3.4 Separação base treino e teste

Para treinamento e avaliação do modelo, os dados foram divididos em duas bases de forma aleatória, uma de teste (30%) e outra de treino (70%). Essa quebra utilizou como premissa manter a mesma porcentagem para a variável alvo (cadastro normal ou não).

3.5 Dados desbalanceados

Analisando a variável alvo podemos identificar um forte desbalanceamento, uma vez que a classe minoritária apresenta uma quantidade de 8647 casos considerados não normais (0.46%) e a classe majoritária apresenta 1865983 casos considerados normais (99,54%). Olhando para base de treinamento mantemos proporções parecidas tendo 6053 casos da classe minoritária (0.46%) e 1306188 casos da classe majoritária (99,54%).

Para corrigir tal situação e não prejudicar a etapa de treinamento, foi utilizado o algoritmo de sobre amostragem SMOTE (*Synthetic Minority Over-sampling*). Após sua aplicação, a base de treinamento apresentou um total de 1306188 casos na classe minoritária (50%) e 1306188 casos na classe majoritária (50%).

3.6 Aplicação dos modelos e ajuste de hiperparâmetros

Os modelos aplicados foram Regressão Logística, *Gradient Boosting* e *Random Forest*. Para melhor obtenção de resultados satisfatórios, a aplicação da técnica de Tunagem de Hiperparâmetros pode ser eficaz (ZHANG, Baohe et al.). Ainda segundo os autores, hiperparâmetros são configurações lógicas de entrada em cada algoritmo que podem influenciar a forma que ele irá trabalhar. A tunagem se baseia em testar diversas combinações de hiperparâmetros e avaliar os resultados do modelo baseado em alguma métrica de avaliação.

Conforme exemplificado na Figura 2 - Fluxo antifraude transacional proposto, o modelo não irá tomar a decisão final de casos considerados fraudulentos e o que buscamos é evitar o envio de transações normais para o modelo terceirizado, dessa forma, o acerto da classe positiva é o que buscamos otimizar. Nesse cenário, a métrica utilizada para escolher a melhor combinação foi a precisão.

As escolha dos parâmetros e possibilidades a se testarem foram escolhidas segundo:

- Recomendação da documentação da biblioteca de cada algoritmo para escolha de parâmetros que mais influenciam no acerto da predição;
- Recomendação da documentação da biblioteca de cada algoritmo para escolha da faixa de valores para cada parâmetro;
- Seleção de no máximo 4 possibilidades para cada parâmetro devido ao alto custo computacional, uma vez que é necessário treinar e avaliar o modelo para cada combinação possível.

Para a execução de treinamento de todas as possibilidades e seleção da melhor combinação foi utilizado o *GridSearchCV* disponibilizado pela biblioteca *Sklearn*.

3.6.1 Hiperparâmetros *Gradient Boosting*

Para o modelo de *Gradient Boosting* os parâmetros e combinações escolhidas foram:

- max_bin
    - Valores: 200, 240, 280, 320
    - Explicação: número máximo de compartimentos nos quais os valores de recurso serão agrupados
- num_leaves
    - Valores: 20, 1020, 2020, 3020
    - Explicação: número máximo de folhas em uma árvore
- learning_rate
    - Valores: 0.01, 0.11, 0.21, 0.31
    - Explicação: taxa de aprendizado/encolhimento
- n_estimators
    - Valores: 10, 110, 210, 310, 410
    - Explicação: número de iterações de "*boosting*"

Foram geradas um total de 320 combinações, onde a combinação: learning_rate = 0.31, max_bin = 320, n_estimators = 10 e num_leaves = 3020 apresentou o melhor resultado com 0.99706% de precisão.

3.6.2 Hiperparâmetros Regressão Logística

Para o modelo de Regressão Logística os parâmetros e combinações escolhidas foram:

- penalty
    - Valores: L1, L2, elasticnet, none
    - Explicação: algoritmo utilizado na penalização pelo erro
- solver
    - Valores: lbfgs, newton-cg, liblinear, sag, saga
    - Explicação: Algoritmo utilizado no problema de otimização
- max_iter

    - Valores: 100, 2500, 5000
    - Explicação: número de iterações para todas as classes
- C
    - Valores: 0.00026, 29, 3792
    - Explicação: Inverso da força de regularização

Foram geradas um total de 320 combinações, onde a combinação: C = 29, max_iter = 2500, penalty = l2, solver = lbfgs apresentou o melhor resultado com 0.99619% de precisão.

3.6.3 Hiperparâmetros *Random Forest*

Para o modelo de *Random Forest* os parâmetros e combinações escolhidas foram:

- n_estimators
    - Valores: 5, 50, 100
    - Explicação: número de árvores na floresta
- max_features
    - Valores: auto, sqrt
    - Explicação: o número de recursos a serem considerados ao procurar a melhor divisão
- max_depth
    - Valores: 10, 65, 120
    - Explicação: a profundidade máxima da árvore
- min_samples_split
    - Valores: 2, 6, 10
    - Explicação: número mínimo de amostras necessárias para dividir um nó interno
- min_samples_leaf
    - Valores: 1, 3, 4
    - Explicação: número mínimo de amostras necessárias para estar em um nó folha
- bootstrap
    - Valores: True, False

- Explicação: se as amostras de inicialização são usadas ao construir árvores

Foram geradas um total de 324 combinações, onde a combinação: bootstrap = False, max_depth = 65, max_features = auto, min_samples_leaf = 1, min_samples_split = 2, n_estimators = 50 apresentou o melhor resultado com 0.99690% de precisão.

3.7 Limiar de classificação

Os três modelos utilizados atribuem uma probabilidade, de 0 a 1, da classe positiva ocorrer. Com essa resposta podemos definir um limiar, onde acima dessa probabilidade a classe é classificada como positiva, caso contrário é classificada como negativa.

A decisão do limiar de classificação pode influenciar o acerto ou não da classe preditora. Dessa forma, para análise do melhor ponto de corte foram analisados 1000 valores do limiar (0.001 até 0.999).

3.8 Resultados

Para análise dos resultados temos dois passos, (i) avaliar o modelo de forma enviesada para o acerto da classe positiva; e (ii) disponibilizar os melhores resultados dentro de faixas que representam a possibilidade de evitar o envio de até determinado percentual das requisições para o modelo antifraude.

Considerando que o Verdadeiro Positivo (VP) é equivalente ao acerto dos cadastros normais e o Falso Positivo (FP) é equivalente ao erro onde consideramos o cadastro normal, porém ele era anormal, as métricas utilizadas para análise foram: VP, FP, precisão e porcentagem de envio para o segundo modelo. Essa última métrica consiste na soma de todos os valores com predição negativa (VN e FN) sobre a soma total (VP, FP, VN e FN).

Para a criação das faixas, os resultados foram quebrados em cinco segmentos baseados na porcentagem de envio para o segundo modelo:

- Porcentagem de envio menor que 20%
- Porcentagem de envio maior ou igual a 20% e menor que 40%

- Porcentagem de envio maior ou igual a 40% e menor que 60%
- Porcentagem de envio maior ou igual a 60% e menor que 80%
- Porcentagem de envio maior ou igual a 80% e menor ou igual a 100%

Em seguida, dentro de cada faixa, foi escolhido o limiar que apresentasse o melhor resultado da métrica precisão, criando-se 5 registos para cada um dos modelos, conforme a Tabela 1 - Resultados *Gradient Boosting*, Tabela 2 - Resultados Regressão Logística e Tabela 3 - Resultados *Random Forest*.

Tabela 1 - Resultados *Gradient Boosting*

Limiar	VP	FP	Precisão	% Envio	Faixa
0.965	450593	500	0.9988916	19.79	< 20%
0.974	388607	381	0.9990205	30.83	>= 20% e < 40%
0.976	300734	298	0.9990101	46.47	>= 40% e < 60%
0.977	210624	197	0.9990656	62.51	>= 60% e < 80%
0.978	97634	112	0.9988542	82.62	>= 80% e <=100%

Fonte: o autor (2022)

Como exemplo para os resultados de *Gradient Boosting*, temos na faixa abaixo de 20%, o limiar de 0.965 apresentando o melhor resultado dado uma precisão de 0.9988916. Neste cenário, não estamos enviando 450593 transações que são realmente cadastros normais, utilizando o modelo terceirizado somente em 19.79% dos casos e assumindo um risco de 500 erros.

Tabela 2 - Resultados Regressão Logística

Limiar	VP	FP	Precisão	% Envio	Faixa
0.812	449665	597	0.9986741	19.94	< 20%
0.942	338315	299	0.9991170	39.79	>= 20% e < 40%
0.982	225149	140	0.9993786	59.94	>= 40% e < 60%
0.996	112548	44	0.9996092	79.98	>= 60% e < 80%
0.999	49647	12	0.9997584	91.17	>= 80% e <= 100%

Fonte: o autor (2022)

Como exemplo para os resultados da Regressão Logística, temos na faixa abaixo de 20%, o limiar de 0.812 apresentando o melhor resultado dado uma precisão de 0.9986741. Neste cenário, não estamos enviando 449665 transações que são realmente cadastros normais, utilizando o modelo terceirizado somente em 19.94% dos casos e assumindo um risco de 597 erros.

Tabela 3 - Resultados *Random Forest*

Limiar	VP	FP	Precisão	% Envio	Faixa
0.961	499176	588	0.9988234	11.136	< 20%
0.981	428468	420	0.9990207	23.74	>= 20% e < 40%
Sem valores					>= 40% e < 60%
					>= 60% e < 80%
					>= 80% e <= 100%

Fonte: o autor (2022)

Como exemplo para os resultados do *Random Forest*, temos na faixa abaixo de 20%, o limiar de 0.961 apresentando o melhor resultado dado uma precisão de 0.9988234. Neste cenário, não estamos enviando 499176 transações que são realmente cadastros normais, utilizando o modelo terceirizado somente em 11.136% dos casos e assumindo um risco de 588 erros. Já as três últimas faixas não apresentaram resultados.

5 CONSIDERAÇÕES FINAIS

Analisando os resultados do modelo *Gradient Boosting* apresentados pela Tabela 2, podemos observar erros baixos na classe positiva, sendo 500 registros na faixa de maior exposição de risco e 112 na faixa de menor risco. O modelo de Regressão Logística segue o mesmo padrão de erros baixos em todas as faixas, apresentando 597 na faixa de maior risco e 12 na faixa de menor risco. De forma contrária, o modelo de *Random Forest* apresentou resultados somente nas faixas abaixo de 40% de envios, apresentando seu melhor resultado na faixa de 20 á 40% com 420 erros.

Para comparar os resultados e buscar o melhor modelo, foi realizada a sumarização dos resultados dos três modelos por cada faixa conforme Tabela 4, Tabela 5, Tabela 6, Tabela 7 e Tabela 8.

Tabela 4 - Comparação dos modelos faixa menor que 20%

Limiar	VP	FP	Precisão	% Envio	Modelo
0.965	450593	500	0.9988916	19.79	Gradient Boosting
0.812	449665	597	0.9986741	19.94	Regressão Logística
0.961	499176	588	0.9988234	11.136	Random Forest

Fonte: o autor (2022)

Para a faixa de envio menor que 20%, onde ocorre maior exposição ao risco de erro, porém, com maior economia no quesito utilização do modelo antifraude terceiro, temos o modelo *Gradient Boosting* obtendo o melhor resultado de registros Verdadeiros Positivos e menor registros de Falsos Positivos. A melhor classificação é seguida pela Regressão Logística e por último *Random Forest.*

Tabela 5 - Comparação dos modelos faixa maior ou igual a 20% e menor que 40%

Limiar	VP	FP	Precisão	% Envio	Modelo
0.974	388607	381	0.9990205	30.83	Gradient Boosting
0.942	338315	299	0.9991170	39.79	Regressão Logística
0.981	428468	420	0.9990207	23.74	Random Forest

Fonte: o autor (2022)

Para a faixa de envio maior ou igual a 20% e menor que 40%, onde temos uma exposição intermediária ao risco, o modelo de *Random Forest* apresentou

maior acerto de registros Verdadeiros Positivos, porém com maior quantidade de erros. Já o modelo de *Gradiente Boosting* se mantém intermediário nos acertos e erros da classe positiva. Por último, o modelo de Regressão Logística apresenta o menor erro e menor acerto da classe positiva.

Tabela 6 - Comparação dos modelos faixa maior ou igual a 40% e menor que 60%

Limiar	VP	FP	Precisão	% Envio	Modelo
0.976	300734	298	0.9990101	46.47	Gradient Boosting
0.982	225149	140	0.9993786	59.94	Regressão Logística
Sem dados					Random Forest

Fonte: o autor (2022)

Para a faixa de envio maior ou igual a 40% e menor que 60%, onde temos uma exposição intermediária ao risco, o modelo de *Gradiente Boosting* apresentou maior acerto de registros Verdadeiros Positivos, porém com maior quantidade de erros. Já o modelo de Regressão Logística apresentou menor erro e menor acerto da classe positiva. Por último, o modelo de *Random Forest* não apresentou dados para para comparação, sendo o modelo a ser descartado nessa faixa.

Tabela 7 - Comparação dos modelos faixa maior ou igual a 60% e menor que 80%

Limiar	VP	FP	Precisão	% Envio	Modelo
0.977	210624	197	0.9990656	62.51	Gradient Boosting
0.996	112548	44	0.9996092	79.98	Regressão Logística
Sem dados					Random Forest

Fonte: o autor (2022)

Para a faixa de envio maior ou igual a 60% e menor que 80%, onde temos uma exposição intermediária ao risco, o modelo de *Gradiente Boosting* apresentou maior acerto de registros Verdadeiros Positivos, porém com maior quantidade de erros. Já o modelo de Regressão Logística apresentou menor erro e menor acerto da classe positiva. Por último, o modelo de *Random Forest* não apresentou dados para para comparação, sendo o modelo a ser descartado nessa faixa.

Tabela 8 - Comparação dos modelos faixa maior ou igual a 80% e menor ou igual a 100%

Limiar	VP	FP	Precisão	% Envio	Modelo
0.978	97634	112	0.9988542	82.62	Gradient Boosting
0.999	49647	12	0.9997584	91.17	Regressão Logística
Sem dados					Random Forest

Fonte: o autor (2022)

Para a faixa de envio maior ou igual a 80% e menor ou igual a 100%, onde ocorre a menor exposição ao risco de erro, porém, com a menor economia no quesito utilização do modelo antifraude terceiro, temos o modelo de *Gradient Boosting* apresentando o maior acerto e maior erro na classe positiva. Em seguida, o modelo de Regressão Logística apresentou o menor erro e acerto da classe positiva. Por último, o modelo de *Random Forest* não apresentou dados para para comparação, sendo o modelo a ser descartado nessa faixa.

Com um baixo volume de erros da classe positiva em todas as faixas para os modelos de *Gradient Boosting* e Regressão Logística, é alcançada a possibilidade de evitar o envio de até 80% das requisições para o modelo antifraude terceiro. Dessa forma, podemos considerar a aplicação dos modelos de *Gradient Boosting* e Regressão Logística satisfatório para atender os objetivos do trabalho, diminuindo a quantidade de transações processadas pela empresa especializada em antifraude.

REFERÊNCIAS

BREIMAN, Leo. Random forests. **Machine learning**, v. 45, n. 1, p. 5-32, 2001.

LAVALLEY, Michael P. Logistic regression. **Circulation**, v. 117, n. 18, p. 2395-2399, 2008.

CLEARSALE. Chargeback: entenda o que é e evite colocar seu negócio em risco. 20 out. 2022. Disponível em: https://blogbr.clear.sale/chargeback-saiba-o-que-quais-os-riscos-e-como-evit-lo. Acesso em: 20 out. 2022.

CLEARSALE. Mapa da Fraude. Disponível em: https://br.clear.sale/mapa-da-fraude. Acesso em: 20 out. 2022.

HAIBO, He; YUNQIAN, Ma. Imbalanced learning: foundations, algorithms, and applications. **Wiley-IEEE Press**, v. 1, p. 27, 2013.

IZBICKI, Rafael; DOS SANTOS, Tiago Mendonça. **Aprendizado de máquina: uma abordagem estatística**. Rafael Izbicki, 2020.0.

KUHN, Max et al. **Applied predictive modeling**. New York: Springer, 2013.

MCC-ENET. Índice de Faturamento online. Disponível em: https://www.mccenet.com.br/indice-de-faturamento-online. Acesso em: 20 out. 2022.

NADIM, Abrar Hayat et al. Analysis of machine learning techniques for credit card fraud detection. In: **2019 International Conference on Machine Learning and Data Engineering (iCMLDE)**. IEEE, 2019. p. 42-47.

NAJEM, Suha M.; KADEEM, Suhad M. A survey on fraud detection techniques in e-commerce. **Tech-Knowledge**, v. 1, n. 1, p. 33-47, 2021.

NATEKIN, Alexey; KNOLL, Alois. Gradient boosting machines, a tutorial. **Frontiers in neurorobotics**, v. 7, p. 21, 2013

TRIVEDI, Naresh Kumar et al. An efficient credit card fraud detection model based on machine learning methods. **International Journal of Advanced Science and Technology**, v. 29, n. 5, p. 3414-3424, 2020.

ROUT, Minakhi et al. Analysis and comparison of credit card fraud detection using machine learning. In: **Artificial Intelligence and Machine Learning in Business Management**. CRC Press, 2021. p. 81-93.

RUTHERFORD, Andrew. **Introducing Anova and Ancova. Introducing Anova and Ancova,** p. 1-192, 2000.

SEBRAE. Uma breve definição sobre o comércio online. 14 jan. 2019. Disponível em: https://www.sebrae.com.br/sites/PortalSebrae/artigos/uma-breve-definicao-sobre-o-comercio-online,08cfa5d3902e2410VgnVCM100000b272010aRCRD. Acesso em: 20 out. 2022.

ZHANG, Baohe et al. On the importance of hyperparameter optimization for model-based reinforcement learning. In: **International Conference on Artificial Intelligence and Statistics**. PMLR, 2021. p. 4015-4023.