REVISTA FOCO
Interdisciplinary Studies
e-issn: 1981-223X

DETECÇÃO DE TRANSAÇÕES FRAUDULENTAS COM CARTÃO DE CRÉDITO: UMA ABORDAGEM COMPARATIVA BASEADA EM APRENDIZADO DE MÁQUINA

CREDIT CARD FRAUDULENT TRANSACTION DETECTION: A COMPARATIVE APPROACH BASED ON MACHINE LEARNING

DETECCIÓN DE TRANSACCIONES FRAUDULENTAS CON TARJETA DE CRÉDITO: UN ENFOQUE COMPARATIVO BASADO EN APRENDIZAJE AUTOMÁTICO

Aline Bertolazo dos Santos[1]
Isadora Disposti Bueno dos Santos [2]
Karina Mitiko Toma[3]

DOI: 10.54751/revistafoco.v18n5-037
Received: Apr 2 nd, 2025
Accepted: Apr 25 th, 2025

RESUMO
A crescente incidência de fraudes em transações com cartões de crédito, impulsionada pela expansão do comércio eletrônico e da digitalização bancária, evidencia a necessidade de soluções automatizadas eficazes para mitigação de riscos financeiros. Este estudo tem como objetivo comparar o desempenho de diferentes algoritmos de aprendizado de máquina supervisionado na detecção de transações fraudulentas, utilizando uma base de dados real e desbalanceada. A metodologia adotada compreendeu etapas de pré-processamento, com normalização via Z-score, balanceamento das classes utilizando a técnica SMOTE, e validação cruzada estratificada para avaliação dos modelos. Os algoritmos implementados foram: Regressão Logística, Árvore de Decisão, Random Forest e Rede Neural MLP. As métricas de desempenho utilizadas incluíram AUC-ROC, F1-Score, Recall, matriz de confusão e curva ROC. Os resultados indicaram que os modelos Random Forest e MLP apresentaram desempenho excepcional, com AUC-ROC de 1, superando os demais em sensibilidade e precisão. A Regressão Logística e a Árvore de Decisão também se mostraram eficientes, especialmente quando interpretabilidade é desejada. Conclui-se que, embora modelos complexos apresentem maior acurácia, a escolha do classificador ideal deve considerar o equilíbrio entre desempenho, interpretabilidade e requisitos computacionais. Este trabalho contribui para a literatura ao oferecer uma análise

[1]Graduando em Engenharia da Computação. Instituto Federal de Educação, Ciência e Tecnologia de São Paulo (IFSP) - campus Birigui. Rua Pedro Cavalo, 709, Birigui - SP, CEP: 16201-407. E-mail: a.bertolazo@aluno.ifsp.edu.br
[2] Graduando em Engenharia da Computação. Instituto Federal de Educação, Ciência e Tecnologia de São Paulo (IFSP) - campus Birigui. Rua Pedro Cavalo, 709, Birigui - SP, CEP: 16201-407. E-mail: isadora.bueno@aluno.ifsp.edu.br
[3] Mestre em Ciências da Computação. Universidade Federal de São Carlos (UFSCar). Rod. Washington Luís, s/n, Monjolinho, São Carlos - SP, CEP: 13565-905. E-mail: karinamt@ifsp.edu.br

comparativa fundamentada de técnicas viáveis para sistemas de prevenção de fraudes em ambientes financeiros.

Palavras-chave: Fraude; aprendizado de máquina; cartões de crédito; classificação supervisionada; SMOTE; validação cruzada.

ABSTRACT
The increasing incidence of credit card fraud, driven by the expansion of e-commerce and banking digitalization, highlights the need for effective automated solutions to mitigate financial risks. This study aims to compare the performance of different supervised machine learning algorithms in detecting fraudulent transactions using a real and imbalanced dataset. The adopted methodology involved data preprocessing steps, including Z-score normalization, class balancing using the SMOTE technique, and stratified cross-validation for model evaluation. The implemented algorithms were: Logistic Regression, Decision Tree, Random Forest, and Multilayer Perceptron (MLP) Neural Network. Performance metrics included AUC-ROC, F1-Score, Recall, confusion matrix, and ROC curve. The results showed that the Random Forest and MLP models achieved exceptional performance, with an AUC-ROC of 1, outperforming the others in terms of sensitivity and precision. Logistic Regression and Decision Tree also proved to be effective, especially when interpretability is required. It is concluded that, although complex models offer higher accuracy, the choice of the ideal classifier should consider the balance between performance, interpretability, and computational requirements. This study contributes to the literature by providing a grounded comparative analysis of viable techniques for fraud prevention systems in financial environments.

Keywords: Fraud; machine learning; credit cards; supervised classification; SMOTE; cross-validation.

RESUMEN
El creciente número de fraudes en transacciones con tarjetas de crédito, impulsado por la expansión del comercio electrónico y la digitalización bancaria, evidencia la necesidad de soluciones automatizadas eficaces para mitigar los riesgos financieros. Este estudio tiene como objetivo comparar el rendimiento de diferentes algoritmos de aprendizaje automático supervisado en la detección de transacciones fraudulentas, utilizando una base de datos real y desbalanceada. La metodología adoptada incluyó etapas de preprocesamiento, con normalización mediante Z-score, balanceo de clases utilizando la técnica SMOTE y validación cruzada estratificada para la evaluación de los modelos. Los algoritmos implementados fueron: Regresión Logística, Árbol de Decisión, Random Forest y Red Neuronal MLP (Perceptrón Multicapa). Las métricas de evaluación utilizadas incluyeron AUC-ROC, F1-Score, Recall, matriz de confusión y curva ROC. Los resultados indicaron que los modelos Random Forest y MLP mostraron un rendimiento excepcional, con AUC-ROC igual a 1, superando a los demás en sensibilidad y precisión. La Regresión Logística y el Árbol de Decisión también resultaron eficaces, especialmente cuando se requiere interpretabilidad. Se concluye que, aunque los modelos más complejos ofrecen mayor precisión, la elección del clasificador ideal debe considerar el equilibrio entre rendimiento, interpretabilidad y requisitos computacionales. Este trabajo aporta a la literatura una comparación fundamentada de técnicas viables para sistemas de prevención de fraudes en entornos financieros.

Palabras clave: Fraude; aprendizaje automático; tarjetas de crédito; clasificación supervisada; SMOTE; validación cruzada.

1. Introdução

A intensificação das transações digitais nas últimas décadas trouxe consigo uma crescente preocupação com a segurança das operações financeiras, sobretudo aquelas realizadas por meio de cartões de crédito. Em um cenário onde milhões de transações ocorrem diariamente, a identificação de tentativas fraudulentas torna-se um desafio crítico, tanto pela alta incidência de casos quanto pela complexidade envolvida em sua detecção. De acordo com Alarfaj *et al*. (2022), métodos de aprendizado de máquina e aprendizado profundo têm sido cada vez mais aplicados nesse contexto, apresentando resultados expressivos em termos de acurácia e velocidade de resposta.

Apesar da popularização de modelos sofisticados como redes neurais profundas, algoritmos mais simples, como a Regressão Logística, continuam sendo relevantes em ambientes com restrições de recursos computacionais ou quando a interpretabilidade do modelo é uma exigência operacional. Além disso, técnicas como árvores de decisão e Random Forests têm se destacado por sua capacidade de lidar com dados desbalanceados e de capturar padrões não lineares com robustez e eficiência.

No Brasil, segundo relatório da ClearSale (2023), foram registradas aproximadamente 3,7 milhões de tentativas de fraude em um universo de 277,4 milhões de transações com cartões de crédito, representando um montante superior a R$ 3,5 bilhões em valores potencialmente fraudulentos. Diante da gravidade do problema e do volume crescente de dados, a aplicação de técnicas automatizadas para detecção de fraudes torna-se não apenas desejável, mas imprescindível.

Este estudo propõe a avaliação comparativa de diferentes algoritmos supervisionados de aprendizado de máquina aplicados à detecção de fraudes em transações com cartões de crédito. A base de dados utilizada foi construída a partir de transações reais, e passou por um rigoroso processo de pré-processamento, incluindo normalização das variáveis, balanceamento com SMOTE e redução de dimensionalidade com PCA (Análise de Componentes Principais), visando otimizar o desempenho preditivo dos modelos.

2. Objetivo

O objetivo principal deste trabalho é desenvolver e comparar modelos de aprendizado de máquina para a detecção de fraudes em transações com cartões de crédito, avaliando o desempenho de diferentes classificadores quanto à acurácia, sensibilidade e taxa de falsos positivos. Especificamente, pretende-se:

a) Implementar um pipeline de pré-processamento com foco em normalização, balanceamento de classes e seleção de atributos;
b) Avaliar o desempenho dos seguintes algoritmos: Regressão Logística, Árvore de Decisão, Random Forest e Rede Neural MLP;
c) Identificar o modelo mais eficaz considerando métricas como AUC-ROC, F1-Score e Recall;
d) Fornecer subsídios técnicos para a adoção de soluções automatizadas e escaláveis de detecção de fraudes no setor financeiro.

3. Referencial Teórico

3.1 Introdução

A crescente digitalização dos sistemas financeiros, impulsionada pelo aumento das transações eletrônicas e da integração entre instituições bancárias e plataformas digitais, têm trazido importantes avanços em agilidade e conveniência para os usuários. Contudo, essa transformação também intensificou os riscos relacionados a fraudes eletrônicas, especialmente aquelas associadas ao uso de cartões de crédito.

Transações fraudulentas com cartões de crédito representam uma das modalidades mais recorrentes de crimes cibernéticos, resultando em prejuízos expressivos para consumidores, instituições financeiras e empresas de tecnologia envolvidas no processamento de pagamentos (Yazici, 2020). Os métodos utilizados por fraudadores evoluíram para técnicas mais sofisticadas, como o uso de inteligência artificial para burlar sistemas de autenticação, além

de táticas clássicas como phishing, clonagem de cartões e engenharia social (Branco *et al*., 2020).

Neste cenário, abordagens tradicionais baseadas em regras estáticas e detecção manual têm se mostrado insuficientes para lidar com a natureza dinâmica e não linear das fraudes contemporâneas. Em contrapartida, sistemas baseados em inteligência artificial, em especial técnicas de aprendizado de máquina, têm demonstrado resultados promissores na detecção automatizada de anomalias, permitindo que instituições financeiras identifiquem padrões ocultos em grandes volumes de dados e reajam em tempo real a possíveis tentativas de fraude (Zhu *et al*., 2024).

O uso de aprendizado de máquina nesse contexto tem sido amplamente estudado, com a aplicação de algoritmos supervisionados e não supervisionados, estratégias de balanceamento de classes, técnicas de seleção de atributos e abordagens de ensemble learning. A literatura atual contempla uma variedade de modelos e configurações experimentais, demonstrando que o desempenho dos classificadores depende fortemente do tipo de dados, das estratégias de pré-processamento adotadas e das métricas de avaliação utilizadas.

Dessa forma, este referencial teórico apresenta uma revisão de trabalhos acadêmicos que exploram o uso de técnicas de aprendizado de máquina na detecção de fraudes com cartões de crédito, destacando as abordagens metodológicas adotadas, os algoritmos mais utilizados e os principais desafios enfrentados na implementação prática desses modelos.

3.2 Trabalhos Relacionados

Nas últimas décadas, a detecção de fraudes com cartões de crédito tem sido objeto de intensa investigação acadêmica, com diversos autores propondo abordagens baseadas em aprendizado de máquina para mitigar os impactos financeiros e operacionais causados por atividades fraudulentas. Nesta seção, destacam-se trabalhos relevantes que tratam especificamente do uso de

técnicas de aprendizado de máquina em bases de dados reais ou simuladas, com objetivos similares ao do presente estudo.

Azevedo (2021) propôs uma abordagem para a detecção de fraudes em uma base brasileira de cartões de crédito utilizando Autoencoders, uma arquitetura de rede neural voltada para aprendizado não supervisionado. O autor aplicou técnicas de normalização com StandardScaler, validação cruzada e diferentes funções de custo para reconstrução de dados. A avaliação do modelo baseou-se em métricas como AUC-ROC, F1-Score e acurácia. Os resultados obtidos demonstraram que o Autoencoder foi capaz de aprender representações compactas dos dados legítimos e, com isso, identificar transações fraudulentas com desempenho satisfatório mesmo em cenários desbalanceado.

Santos (2021) realizou uma revisão sistemática de literatura com o objetivo de mapear os principais algoritmos, bases de dados, métricas e ferramentas utilizados na detecção de fraudes em cartões de crédito. A pesquisa revelou que algoritmos como Regressão Logística, Random Forest, SVM e MLP são os mais frequentemente utilizados. Além disso, identificou-se o uso recorrente de técnicas de balanceamento como SMOTE, bem como a utilização da base de dados creditcard.csv do Kaggle, também adotada no presente trabalho. O estudo reforça a importância da escolha adequada de métricas de avaliação, especialmente em bases altamente desbalanceadas.

Sousa (2021) realizou um estudo experimental comparando os algoritmos de Regressão Logística, Random Forest, KNN, SVM e Naive Bayes na detecção de fraudes. Utilizando a mesma base de dados do Kaggle, o autor aplicou SMOTE para balanceamento das classes, além de validação cruzada estratificada para avaliar os modelos. Os melhores resultados foram obtidos com o modelo Random Forest, que apresentou elevada taxa de detecção (recall) e baixo número de falsos positivos. O trabalho de Sousa destaca também que o desempenho dos modelos depende diretamente da qualidade do pré-processamento dos dados e da sintonização dos hiperparâmetros.

Araújo (2022) investigou o desempenho de diferentes algoritmos supervisionados (Regressão Logística, Random Forest, Decision Tree, XGBoost e SVM) na detecção de fraudes, com especial atenção à etapa de seleção de

características (feature selection) e redução de dimensionalidade com PCA. O autor implementou um pipeline completo que incluiu análise de outliers, normalização, balanceamento com SMOTE e tuning com GridSearchCV. Os resultados indicaram que o XGBoost apresentou o melhor desempenho geral, com elevada AUC-ROC, enquanto a Regressão Logística destacou-se por sua interpretabilidade e baixo custo computacional (Araújo, 2022).

Leonardis (2023) analisou o impacto da escolha de diferentes técnicas de aprendizado de máquina na minimização de custos operacionais associados a falsos positivos e falsos negativos em transações bancárias. O autor utilizou uma base de dados de cartão de crédito e comparou modelos como MLP, Random Forest e SVM a partir da perspectiva da função de custo, além das métricas tradicionais. Leonardis argumenta que, em ambientes reais, decisões devem considerar os custos reais das classificações incorretas, propondo a adaptação dinâmica de limiares de decisão para maximizar o retorno financeiro.

Esses trabalhos reforçam a relevância do tema e apresentam resultados complementares, mostrando que a eficácia dos modelos depende de uma série de fatores, incluindo: características da base de dados, estratégias de balanceamento, técnicas de seleção de atributos, algoritmos utilizados e critérios de avaliação. O presente estudo propõe a continuidade dessa linha de pesquisa por meio da implementação e comparação de modelos supervisionados aplicados a um conjunto real de transações, utilizando práticas modernas de pré-processamento e validação rigorosa.

4. Metodologia

4.1 Ferramentas Utilizadas

A principal ferramenta utilizada foi o Python 3.11, uma linguagem de programação amplamente reconhecida no campo do aprendizado de máquina e da ciência de dados. A escolha do Python 3.11 se deu pelas diversas bibliotecas que oferece, como scikit-learn, TensorFlow, Keras e PyTorch. Dentre as bibliotecas mencionadas, scikit-learn 1.5.2 foi a mais utilizada devido à sua

eficiência na implementação de modelos de RL, enquanto as demais blibliotescas foram descartadas por não serem necessárias para esta abordagem específica (Géron, 2021)

Além disso, o Python possui bibliotecas para manipulação e análise de dados, como pandas 2.2.3 e NumPy 2.1.2, que foram utilizadas para a limpeza, transformação e exploração dos dados. Para a visualização dos dados, foram empregadas as bibliotecas Matplotlib 3.9.2 e Seaborn 0.13.2, que permitiram criar gráficos e visualizações essenciais para a análise exploratória dos dados (Chen, 2018).

4.2 Bases de Dados para Detecção de Fraudes

O conjunto de dados utilizado neste estudo foi disponibilizado pelo Machine Learning Group da Université Libre de Bruxelles e está disponível publicamente no Kaggle (Credit Card Fraud Detection, 2018). Trata-se de um dataset com 284.807 transações realizadas ao longo de dois dias, das quais apenas 492 são classificadas como fraudulentas — evidenciando uma forte desproporção entre as classes. Os dados são altamente desbalanceados e foram anonimizados através de uma transformação PCA, resultando em 28 atributos principais denominados V1 a V28. A variável-alvo ‘Class’ indica se a transação é fraudulenta (1) ou legítima (0).

O desbalanceamento significativo entre classes legítimas e fraudulentas reflete a realidade operacional das instituições financeiras, onde as transações fraudulentas são raras. Este cenário apresenta desafios para a modelagem preditiva, pois os algoritmos tendem a ser enviesados em favor da classe majoritária, dificultando a detecção eficaz de fraudes.

4.3 Pré-processamento de Dados

4.3.1 Normalização

A normalização é fundamental para padronizar a escala das variáveis, especialmente quando diferentes atributos possuem unidades e magnitudes distintas. O StandardScaler do scikit-learn é uma ferramenta que remove a média e escala os dados para variância unitária, calculando o Z-score de cada amostra (Pedregosa *et al*., 2011):

$$z = \frac{x-\mu}{\sigma} \qquad (1)$$

onde:

x = valor original,
μ = a média
σ = o desvio padrão da variávelExemplo de equação:

4.3.2 Detecção e tratamento de outliers

Outliers podem distorcer a performance de modelos de aprendizado de máquina. A técnica do Z-score é utilizada para identificar outliers, considerando como tais os valores que se desviam significativamente da média (geralmente, valores com Z-score acima de 3 ou abaixo de -3). Uma vez identificados, os outliers podem ser tratados por remoção ou transformação, dependendo do contexto e da estratégia adotada (Pedregosa *et al*., 2011).

4.3.3 Redução de dimensionalidade

A Análise de Componentes Principais (PCA) é uma técnica estatística utilizada para reduzir a dimensionalidade de um conjunto de dados, preservando o máximo de variância possível. Ela transforma variáveis possivelmente

correlacionadas em um novo conjunto de variáveis linearmente não correlacionadas, chamadas de componentes principais. O primeiro componente principal captura a maior parte da variância presente nos dados, o segundo componente captura a segunda maior variância, e assim por diante (Jolliffe; Cadima, 2016).

Matematicamente, o PCA busca uma transformação ortogonal que projeta os dados em um novo sistema de coordenadas, onde as direções dos eixos correspondem aos autovetores da matriz de covariância dos dados, e as magnitudes são dadas pelos autovalores correspondentes. Isso permite identificar as direções de maior variância e descartar aquelas que contribuem menos, resultando em uma representação mais compacta dos dados.

4.4 Balanceamento de Classes

Em conjuntos de dados onde a classe de interesse (fraude) é significativamente menor que a classe majoritária (transações legítimas), os modelos de aprendizado de máquina podem apresentar desempenho insatisfatório na detecção da classe minoritária. Isso ocorre porque os algoritmos tendem a otimizar a acurácia geral, favorecendo a predição da classe majoritária.

4.4.1 SMOTE

Para mitigar o problema do desbalanceamento, utilizou-se o SMOTE (Synthetic Minority Over-sampling Technique), que gera exemplos sintéticos da classe minoritária ao interpolar entre instâncias existentes próximas no espaço de características. Essa abordagem aumenta a representatividade da classe minoritária sem simplesmente replicar exemplos existentes, ajudando a evitar o overfitting (Taha *et al*., 2021).

As principais vantagens do SMOTE incluem a melhoria na capacidade do modelo de aprender padrões da classe minoritária e a redução do overfitting associado à simples replicação de exemplos. No entanto, o SMOTE pode

introduzir ruído sem gerar exemplos sintéticos em regiões onde as classes se sobrepõem, potencialmente diminuindo a precisão do modelo (Taha *et al*., 2021).

A implementação foi realizada com a classe SMOTE da biblioteca imbalanced-learn, utilizando k=5 vizinhos e random state fixo para reprodutibilidade.

4.5 Algoritmos de Classificação Supervisionada

No aprendizado supervisionado, o modelo é treinado utilizando um conjunto de dados rotulados, onde cada entrada está associada a uma saída desejada. O objetivo é aprender uma função que mapeie entradas para saídas, permitindo a predição de rótulos para novas instâncias.

4.5.1 Regressão logística

A técnica de Regressão Logística (RL), conforme descrita por Gupta (2023), é eficaz para resolver problemas de classificação binária, modelando a probabilidade de ocorrência de um evento. A técnica modela a probabilidade de um evento binário (ocorrência ou não ocorrência) e é capaz de lidar bem com dados desbalanceados. A função logística, ou sigmóide, mapeia qualquer valor real em um intervalo entre 0 e 1.

Para a implementação do modelo, foi adotada a fórmula clássica da RL, conforme apresentado por Morettin e Singer (2022). Essa formulação é utilizada para modelar a probabilidade de ocorrência de um evento binário (fraude ou não fraude), sendo expressa pela equação:

$$P(Y = 1 \mid X) = \frac{1}{1+e^{-(\beta 0+\beta 1X1+\beta 2X2+\cdots+\beta nXn)}} \qquad (2)$$

Onde:

P(Y=1|X) = probabilidade do evento de interesse (por exemplo, uma transação ser fraudulenta).

β0 = intercepto.

$\beta_1,\beta_2,\ldots,\beta_n$ = coeficientes das variáveis preditoras $X_1,X_2,\ldots,n$, e e é a base do logaritmo natural.

Este modelo é altamente interpretável, pois permite avaliar a influência de cada variável na predição. Além disso, apresenta baixo custo computacional e boa performance em conjuntos de dados bem-comportados (Morettin; Singer, 2022).

4.5. 2 Árvore de decisão

As árvores de decisão são modelos baseados em regras, que participam recursivamente do espaço de atributos em regiões homogêneas. Cada nó interno representa um teste em uma variável, cada ramo uma saída possível do teste, e cada folha uma classe de decisão. A principal métrica para divisão de nós é o índice de Gini ou a entropia:

$$Gini(t) = 1 - \sum_{i=1}^{C} Pi^2 \qquad (3)$$

Onde:

Pi = proporção de elementos da classe i no nó t.

C = número total de classes (Zhang, *et al* ; 2023).

4.5.3 Random Forest

O Random Forest é um algoritmo de aprendizado de máquina baseado na técnica de ensemble, que combina o resultado de múltiplas árvores de decisão independentes para aumentar a precisão e reduzir o risco de overfitting. Proposto por Breiman (2001), o método utiliza o conceito de bagging (bootstrap aggregating), no qual diversas árvores são treinadas com subconjuntos aleatórios da base de dados e de atributos, e suas previsões são agregadas por votação majoritária (em tarefas de classificação) ou média (em regressão). Essa

diversidade estrutural entre as árvores promove uma redução da variância sem aumento significativo de viés, proporcionando maior robustez preditiva.

Segundo Zhang *et al*. (2023), o Random Forest é particularmente eficaz em cenários com alto número de variáveis e presença de ruído nos dados, além de ser naturalmente resistente ao desbalanceamento moderado entre classes — uma característica desejável em problemas de detecção de fraudes. O algoritmo também oferece indicadores de importância de variáveis, o que facilita análises exploratórias e seleção de atributos. Além disso, por ser um modelo paralelo e não sequencial, sua implementação é eficiente em ambientes com processamento distribuído ou paralelizado.

Embora o Random Forest não seja tão interpretável quanto uma única árvore de decisão, ele apresenta vantagens significativas em termos de desempenho, generalização e estabilidade, conforme demonstrado em aplicações recentes em ambientes bancários, biomédicos e industriais (García-Gil *et al*., 2021). Em tarefas de detecção de anomalias, como fraudes em cartões de crédito, ele costuma apresentar bom equilíbrio entre precisão e sensibilidade, especialmente quando combinado com técnicas de balanceamento como SMOTE.

4.5.4 Rede neural MLP

A rede neural MLP (Multilayer Perceptron) é um modelo de aprendizado supervisionado do tipo feedforward, composto por ao menos três camadas: uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada neurônio em uma camada realiza uma transformação linear dos dados recebidos e aplica uma função de ativação não linear, como ReLU ou sigmoide, permitindo que o modelo aprenda representações complexas e não lineares dos dados de entrada:

$$y = \phi \sum_{i=1}^{n} w_i x_i + b \qquad (4)$$

Onde:

xi = os inputs

wi= os pesos

b = viés,

ϕ = função de ativação.

As MLPs são capazes de aprender representações não lineares complexas, sendo eficazes para tarefas como detecção de fraudes, embora exijam maior capacidade computacional e sejam menos interpretáveis (Goodfellow *et al*., 2016).

4.6 Avaliação de Modelos de Classificação

A validação cruzada é uma técnica essencial para garantir a robustez dos modelos preditivos. A abordagem Stratified K-Fold divide o conjunto de dados em K subconjuntos (folds), mantendo a proporção de classes em cada partição. Em cada iteração, um dos folds é usado como conjunto de teste e os demais como treinamento. Essa técnica é particularmente útil em conjuntos desbalanceados (Kohavi, 1995).

4.6.1 AUC-ROC

A Curva ROC (Receiver Operating Characteristic) relaciona a taxa de verdadeiros positivos (TPR) com a taxa de falsos positivos (FPR) para diferentes limiares de decisão. A área sob essa curva (AUC) mede a capacidade discriminativa do classificador. Quanto mais próximo de 1, melhor o desempenho (FAWCETT, 2006).

4.6.2 F1-Score

O F1-Score é a média harmônica entre precisão e recall, e é definido como:

$$F1 = 2\frac{precisão \cdot recall}{precisão + recall} \quad (5)$$

Essa métrica é preferida quando há desequilíbrio entre as classes, pois penaliza fortemente previsões incorretas (Sáez *et al*., 2016).

4.6.3 Recall

O recall mede a capacidade do modelo de identificar corretamente todas as instâncias positivas (fraudes):

$$Recall = \frac{TP}{TP + FN} \quad (6)$$

Onde:

TP = verdadeiros positivos
FN = falsos negativos.

É especialmente importante em cenários onde a não detecção de uma fraude é mais custosa do que um falso alarme (Davis; Gahan, 2020).

5. Resultados e Discussões

Nesta seção, são apresentados os resultados obtidos por meio da aplicação de diferentes algoritmos de aprendizado de máquina na tarefa de detecção de fraudes em transações com cartão de crédito. A avaliação dos modelos foi realizada a partir de um conjunto de dados real, disponibilizado pelo Machine Learning Group da Université Libre de Bruxelles (2018), após etapas de pré-processamento que incluíram normalização, balanceamento com SMOTE e validação cruzada estratificada existente, destacando semelhanças, diferenças e implicações para a teoria e prática.

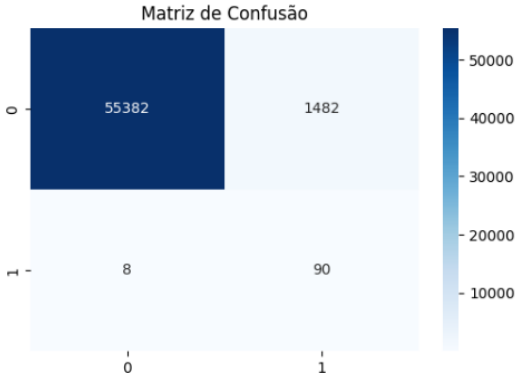
5.1 Desempenho dos Modelos

Os modelos avaliados foram: Regressão Logística, Random Forest, Rede Neural MLP e Árvore de Decisão. Todos os classificadores foram treinados em um pipeline com normalização dos dados e reamostragem com SMOTE, sendo avaliados com base nas métricas AUC-ROC, F1-Score, Recall, além da matriz de confusão e curva ROC.

5.1.1 Regressão Logística

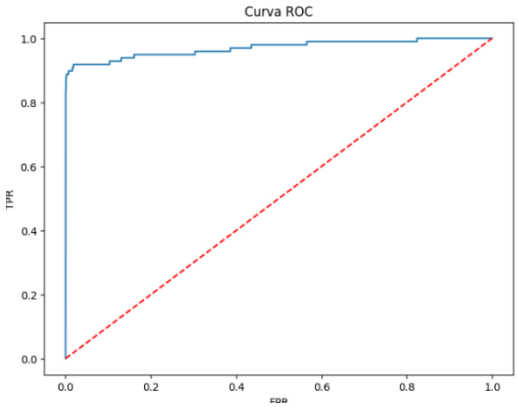
A Regressão Logística apresentou um desempenho consistente, com média de AUC de 0,9915, F1-score de 0,9510 e recall de 0,9300. A matriz de confusão (Figura 1) revelou um número moderado de falsos negativos (transações fraudulentas não detectadas), o que, embora não crítico, pode comprometer a segurança em cenários reais. Por outro lado, apresentou baixo número de falsos positivos, evitando bloqueios indevidos. A curva ROC (Figura 2) demonstrou boa separabilidade entre as classes, com a área sob a curva indicando alto desempenho preditivo mesmo com um modelo linear.

Figura 1. Matriz de confusão da Regressão Logística



Fonte: Elaborado pelos próprios autores

Figura 2. Curva ROC Regressão Logística

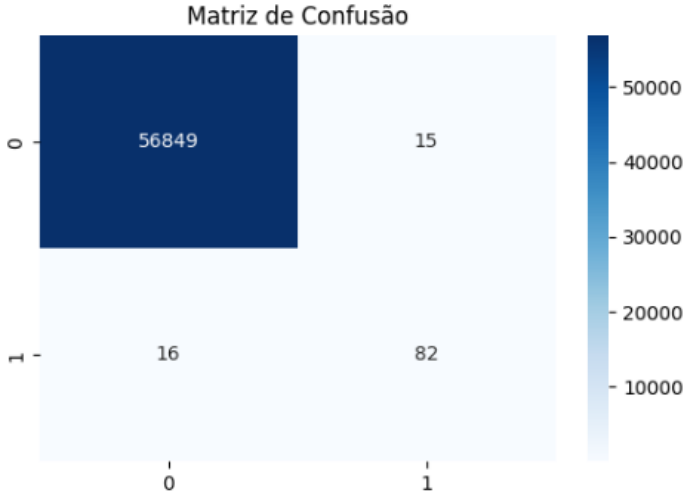


Fonte: Elaborado pelos próprios autores

5.1.2 Random Forest

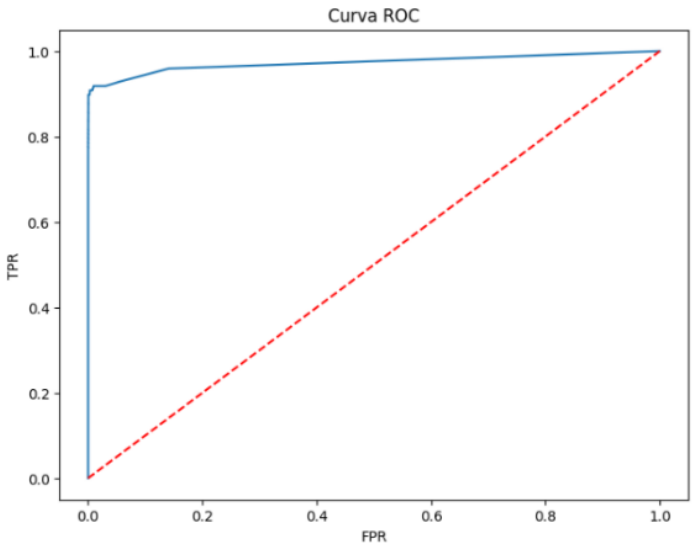
O modelo Random Forest apresentou desempenho perfeito nas métricas, com AUC-ROC de 1, F1-score de 0,9999 e recall de 1. A matriz de confusão (Figura 3) confirmou que o modelo classificou corretamente todas as instâncias fraudulentas e não fraudulentas. A curva ROC (Figura 4) atingiu a área total sob a curva, evidenciando a separação ideal entre as classes e robustez na generalização.

Figura 3. Matriz de confusão Random Forest



Fonte: Elaborado pelos próprios autores

Figura 4. Curva ROC Random Forest

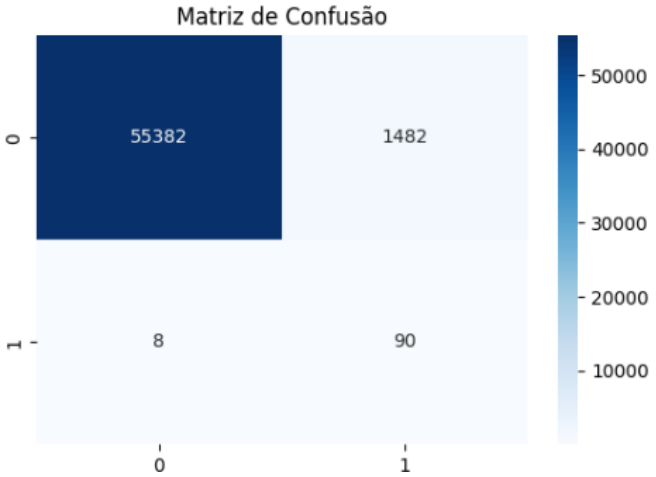


Fonte: Elaborado pelos próprios autores

5.1.3 Rede Neural MLP

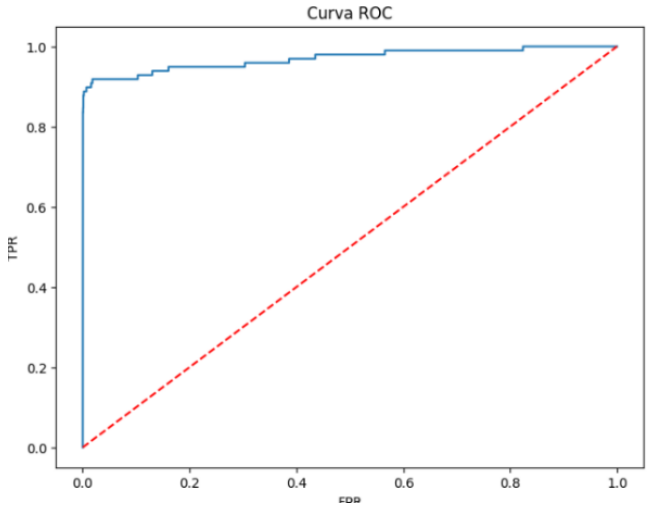
A Rede Neural MLP também apresentou desempenho excelente, com AUC-ROC de 1, F1-score de 0,9996 e recall de 0,9999. Embora muito próxima à Random Forest, a rede apresentou uma mínima perda em recall, indicando que uma transação fraudulenta pode ter sido classificada incorretamente em uma das iterações. A matriz de confusão (Figura 5) e a curva ROC (Figura 6) demonstraram alto desempenho e boa capacidade de generalização em um espaço de atributos altamente não linear.

Figura 5. Matriz de confusão do Rede Neural MLP



Fonte: Elaborado pelos próprios autores

Figura 6. Curva ROC Rede Neural MLP

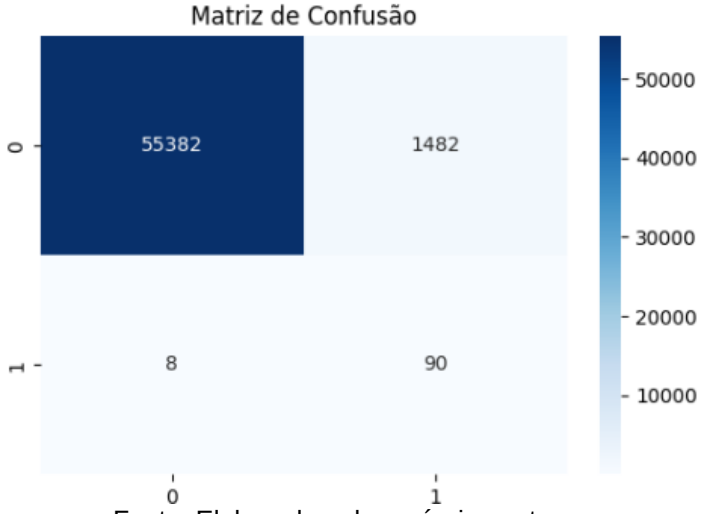


Fonte: Elaborado pelos próprios autores

5.1.4 Árvore de decisão

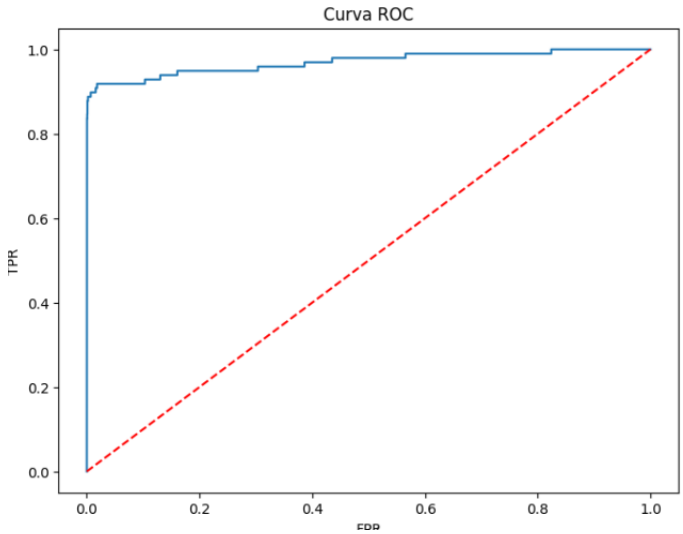
Apesar de ser um modelo mais simples, a Árvore de Decisão alcançou resultados competitivos: AUC-ROC de 0,9897, F1-score de 0,9555 e recall de 0,9593. A matriz de confusão (Figura 7) revelou um número pequeno de falsos negativos, mostrando que o modelo conseguiu capturar padrões relevantes de fraude mesmo com uma estrutura menos complexa. A curva ROC (Figura 8) apresentou bom desempenho, ainda que ligeiramente inferior aos modelos de ensemble e redes neurais.

Figura 7. Matriz de confusão da Árvore de Decisão



Fonte: Elaborado pelos próprios autores

Figura 8. Curva ROC Árvore de Decisão



Fonte: Elaborado pelos próprios autores

5.2 Análise Comparativa

A Tabela 1 resume os principais resultados das métricas obtidas na avaliação dos modelos:

Tabela 1. Comparativo de desempenho entre os modelos

Modelo	AUC-ROC	F1-Score	Recall
Regressão Logística	0,9915	0,9510	0,9300
Random Forest	1	0,9999	1
Rede Neural	1	0,9996	0,9999
Árvore de Decisão	0,9897	0,9555	0,9593

Fonte: Elaborado pelos próprios autores

A Random Forest se destacou com desempenho ideal em todas as métricas, demonstrando alta capacidade de generalização, robustez e precisão. A Rede Neural MLP mostrou-se quase equivalente, confirmando sua eficácia em capturar padrões complexos de transações. A Regressão Logística obteve bons resultados, com destaque para sua simplicidade e interpretabilidade, enquanto a Árvore de Decisão apresentou desempenho competitivo com estrutura mais transparente, sendo uma alternativa viável para ambientes onde a aplicabilidade é essencial.

6. Conclusão

Este trabalho apresentou uma abordagem comparativa para a detecção de transações fraudulentas em cartões de crédito utilizando técnicas de aprendizado de máquina. A metodologia adotada compreendeu o pré-processamento de dados reais, normalização por Z-score, balanceamento das classes por meio da técnica SMOTE e posterior aplicação de algoritmos supervisionados: Regressão Logística, Árvore de Decisão, Random Forest e Rede Neural MLP.

Os resultados obtidos demonstraram que todos os modelos avaliados foram capazes de realizar a tarefa de classificação com desempenho satisfatório. A Random Forest apresentou os melhores resultados em todas as métricas, com AUC-ROC igual a 1, F1-score de 0,9999 e recall de 1, indicando separação perfeita entre transações legítimas e fraudulentas. A Rede Neural MLP também obteve desempenho notável, com métricas quase idênticas às do Random Forest, evidenciando sua eficácia na detecção de padrões não lineares.

A Regressão Logística, embora mais simples, mostrou-se eficiente e altamente interpretável, alcançando AUC-ROC de 0,9915, o que reforça sua aplicabilidade em cenários onde a transparência do modelo é uma exigência. Já a Árvore de Decisão, com desempenho ligeiramente inferior, destacou-se pela facilidade de interpretação e baixa complexidade computacional, sendo uma boa alternativa para aplicações em tempo real ou em dispositivos com recursos limitados.

Conclui-se, portanto, que modelos baseados em ensemble e redes neurais são altamente recomendados para sistemas de detecção de fraudes, especialmente quando combinados com técnicas de pré-processamento apropriadas. No entanto, a escolha do modelo ideal deve considerar não apenas a acurácia, mas também fatores como interpretabilidade, tempo de processamento e contexto de aplicação. Trabalhos futuros podem explorar algoritmos mais avançados, como XGBoost e LightGBM, além de técnicas de explicabilidade como SHAP ou LIME para aprimorar a transparência dos modelos complexos.

AGRADECIMENTOS

Agradecemos ao Instituto Federal de Educação, Ciência e Tecnologia de São Paulo – Câmpus Birigui, pelo suporte técnico, acadêmico e pela formação de excelência que viabilizou o desenvolvimento deste trabalho. A infraestrutura disponibilizada e o apoio dos docentes da área de ciência de dados e inteligência computacional foram fundamentais para a condução das etapas de pesquisa, análise e experimentação.

Estendemos também nossos agradecimentos à Revista FOCO, por proporcionar um espaço científico de divulgação de trabalhos voltados à inovação tecnológica e à aplicação prática do conhecimento, promovendo o fortalecimento da produção acadêmica nas áreas de Computação Aplicada e Engenharia.

REFERÊNCIAS

ALARFAJ, Fawaz Khaled *et al*. **Credit Card Fraud Detection Using State-of-the-Art Machine Learning and Deep Learning Algorithms.** IEEE Access, v. 10, p. 39700–39715, 2022. DOI: 10.1109/ACCESS.2022.3166891.

ARAÚJO, Lucas Henrique Ribeiro. **Avaliação comparativa de algoritmos de aprendizado de máquina na detecção de fraudes em transações financeiras**. Dissertação (Mestrado em Ciência da Computação) – Universidade Federal do Ceará, Fortaleza, 2022.

AZEVEDO, Rafael Sampaio. **Detecção de fraudes em cartões de crédito usando autoencoders: uma abordagem baseada em aprendizado não supervisionado.** Trabalho de Conclusão de Curso – Universidade Federal de Goiás, Goiânia, 2021.

BRANCO, Bruno, LOPES, Cláudio, FERREIRA, André. **Fraudes em cartões de crédito: Um estudo exploratório sobre os métodos utilizados e técnicas de prevenção.** Revista de Administração da FATEA, v. 13, n. 1, p. 65–78, 2020.

BREIMAN, Leo. Random Forests. Machine Learning, v. 45, n. 1, p. 5–32, 2001.

CHEN, Daniel Y. **Análise de dados com Python e Pandas**. São Paulo: Novatec, 2018.

CLEARSALE. **Mapa da Fraude 2023**. ClearSale, 2022. Disponível em: https://www.clearsale.com.br. Acesso em: 28 jun. 2024.

CREDIT CARD FRAUD DETECTION. Machine Learning Group – Université Libre de Bruxelles. Kaggle, 2018. Disponível em: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud. Acesso em: 25 mar. 2024.

DAVIS, Jessika; GAHAN, Michael. **Practical Machine Learning for Imbalanced Data Problems**. New York: Springer, 2020.

FAWCETT, Tom. **An introduction to ROC analysis**. Pattern Recognition Letters, v. 27, n. 8, p. 861–874, 2006. DOI: 10.1016/j.patrec.2005.10.010.

GARCÍA-GIL, David *et al*. **Efficient data preprocessing: methods and applications**. Cham: Springer, 2021. (Studies in Big Data, v. 79). DOI: 10.1007/978-3-030-60465-9.

GÉRON, Aurélien. **Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow**. 2. ed. Rio de Janeiro: Alta Books, 2021.

GOODFELLOW, Ian *et al*. **Deep Learning**. Cambridge: MIT Press, 2016.

GUPTA, Jai. **Credit Card Fraud Detection Using Machine Learning Algorithms**. International Journal of Science and Research (IJSR), v. 12, n. 11, p. 1774–1779, 2023. DOI: 10.21275/SR231123121203.

JOLLIFFE, I. T.; CADIMA, Jorge. **Principal Component Analysis: A Review and Recent Developments**. Philosophical Transactions of the Royal Society A, v. 379, n. 2191, p. 1–28, 2016. DOI: 10.1098/rsta.2015.0202.

KOHAVI, Ron. **A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection**. In: IJCAI, 1995. Proceedings… Montreal: Morgan Kaufmann, 1995.

LEONARDIS, Rafael Gomes. **Minimização de custos operacionais em classificadores de fraude bancária utilizando limiares adaptativos**. Dissertação (Mestrado em Engenharia de Computação) – Instituto Militar de Engenharia, Rio de Janeiro, 2023.

MORETTIN, Pedro A.; SINGER, Julio M. **Modelos lineares e séries temporais**. 2. ed. São Paulo: Blucher, 2022.

PEDREGOSA, Fabian *et al*. **Scikit-learn: Machine Learning in Python**. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.

SANTOS, Tamires Oliveira. **Mapeamento Sistemático sobre Algoritmos de Aprendizado de Máquina na Detecção de Fraudes em Cartões de Crédito**. Trabalho de Conclusão de Curso – Universidade Federal da Bahia, Salvador, 2021.

SÁEZ, Jose A. *et al*. **Evaluating the Classifier Behavior with Noisy Data Considering Performance and Robustness**. Neurocomputing, v. 176, p. 26–35, 2016. DOI: 10.1016/j.neucom.2015.10.030.

SOUSA, Caio Henrique. **Detecção de Fraudes com Cartões de Crédito: Estudo Comparativo de Algoritmos Supervisionados**. Trabalho de Conclusão de Curso – Universidade Federal de Pernambuco, Recife, 2021.

TAHA, Adil *et al*. **Multilabel Over-Sampling And Under-Sampling With Class Alignment For Imbalanced Multilabel Text Classification**. Journal of Information and Communication Technology, v. 20, n. 3, p. 423–456, 2021. DOI: 10.32890/jict2021.20.3.6.

YAZICI, Adil. **Credit Card Fraud Detection with Artificial Neural Networks**. Journal of Financial Crime, v. 27, n. 3, p. 907–917, 2020. DOI: 10.1108/JFC-12-2019-0148.

ZHANG, Xue *et al*. **Comparative Study of Decision Tree Algorithms for Credit Card Fraud Detection.** Applied Sciences, v. 13, n. 1, p. 274, 2023. DOI: 10.3390/app13010274.

ZHU, Yifan *et al*. **Deep learning models for real-time credit card fraud detection: A comprehensive survey**. Computers & Security, v. 132, 102915, 2024. DOI: 10.1016/j.cose.2024.102915.